

PRIMJER KORIŠTENJA STROJNOG UČENJA U NLP-u

Mario Kučić







podaci = pd.read_csv('podaci.csv')

učitavanje podataka

```
podaci = pd.read_csv('podaci.csv')
podaci.head()
```


klasa	rijec	
0	posvijetli	0
0	spektakularniju	1
1	monogamist	2
0	prijavu	3
0	fotografiravši	4

učitavanje podataka

podaci = pd.read_csv('podaci.csv')

učitavanje podataka

```
podaci = pd.read_csv('podaci.csv')
rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
    train_test_split(podaci['rijec'], podaci['klasa'],
    test_size=0.2)
```




```
podaci = pd.read_csv('podaci.csv')

rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
    train_test_split(podaci['rijec'], podaci['klasa'],
    test_size=0.2)

transformator = CountVectorizer(
    ngram_range=(1, 3), analyzer='char')


ngram_ucenje = transformator.fit_transform(
    rijeci_ucenje)

ngram_test = transformator.transform(rijeci_test)
```



```
podaci = pd.read_csv('podaci.csv')
rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
    train_test_split(podaci['rijec'], podaci['klasa'],
    test_size=0.2)
transformator = CountVectorizer(
     ngram_range=(1, 3), analyzer='char')
ngram_ucenje = transformator.fit_transform(
      rijeci_ucenje)
ngram_test = transformator.transform(rijeci_test)
                      3-gram
                      prijavu
```

pri rij ija jav avu




```
podaci = pd.read_csv('podaci.csv')

rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
    train_test_split(podaci['rijec'], podaci['klasa'],
    test_size=0.2)


transformator = CountVectorizer(
    ngram_range=(1, 3), analyzer='char')

ngram_ucenje = transformator.fit_transform(
    rijeci_ucenje)


ngram_test = transformator.transform(rijeci_test)
```




```
podaci = pd.read_csv('podaci.csv')
rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
    train_test_split(podaci['rijec'], podaci['klasa'],
    test_size=0.2)
transformator = CountVectorizer(
      ngram_range=(1, 3), analyzer='char')
ngram_ucenje = transformator.fit_transform(
      rijeci_ucenje)
ngram_test = transformator.transform(rijeci_test)
model = RandomForestClassifier(
      n_estimators=100, max_depth=3)
```




```
podaci = pd.read_csv('podaci.csv')
rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
    train_test_split(podaci['rijec'], podaci['klasa'],
    test_size=0.2)
transformator = CountVectorizer(
     ngram_range=(1, 3), analyzer='char')
ngram_ucenje = transformator.fit_transform(
      rijeci_ucenje)
ngram_test = transformator.transform(rijeci_test)
model = RandomForestClassifier(
      n_estimators=100, max_depth=3)
rezultati = cross_val_score(
     model, ngram_ucenje, klase_ucenje)
print(f'Avg F1 {rezultati.mean():.3f}') # Avg F1 0.870
```




```
podaci = pd.read_csv('podaci.csv')
rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
    train_test_split(podaci['rijec'], podaci['klasa'],
    test_size=0.2)
transformator = CountVectorizer(
     ngram_range=(1, 3), analyzer='char')
ngram_ucenje = transformator.fit_transform(
      rijeci_ucenje)
ngram_test = transformator.transform(rijeci_test)
model = RandomForestClassifier(
      n_estimators=100, max_depth=3)
rezultati = cross_val_score(
     model, ngram_ucenje, klase_ucenje)
print(f'Avg F1 {rezultati.mean():.3f}') # Avg F1 0.870
```




```
podaci = pd.read_csv('podaci.csv')
rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
    train_test_split(podaci['rijec'], podaci['klasa'],
    test size=0.2)
transformator = CountVectorizer(
      ngram_range=(1, 3), analyzer='char')
ngram_ucenje = transformator.fit_transform(
      rijeci_ucenje)
ngram_test = transformator.transform(rijeci_test)
model = RandomForestClassifier(
      n_estimators=100, max_depth=3)
rezultati = cross_val_score(
      model, ngram_ucenje, klase_ucenje)
print(f'Avg F1 {rezultati.mean():.3f}') # Avg F1 0.870
model.fit(ngram_ucenje, klase_ucenje)
```



```
podaci = pd.read_csv('podaci.csv')
rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
    train_test_split(podaci['rijec'], podaci['klasa'],
    test size=0.2)
transformator = CountVectorizer(
      ngram_range=(1, 3), analyzer='char')
ngram_ucenje = transformator.fit_transform(
      rijeci_ucenje)
ngram_test = transformator.transform(rijeci_test)
model = RandomForestClassifier(
      n_estimators=100, max_depth=3)
rezultati = cross_val_score(
     model, ngram_ucenje, klase_ucenje)
print(f'Avg F1 {rezultati.mean():.3f}') # Avg F1 0.870
model.fit(ngram_ucenje, klase_ucenje)
predvidjene_klase = model.predict(ngram_test)
```



```
podaci = pd.read_csv('podaci.csv')
rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
    train_test_split(podaci['rijec'], podaci['klasa'],
    test size=0.2)
transformator = CountVectorizer(
      ngram_range=(1, 3), analyzer='char')
ngram_ucenje = transformator.fit_transform(
      rijeci_ucenje)
ngram_test = transformator.transform(rijeci_test)
model = RandomForestClassifier(
      n_estimators=100, max_depth=3)
rezultati = cross_val_score(
      model, ngram_ucenje, klase_ucenje)
print(f'Avg F1 {rezultati.mean():.3f}') # Avg F1 0.870
model.fit(ngram_ucenje, klase_ucenje)
predvidjene_klase = model.predict(ngram_test)
rezultat = f1_score(klase_test, predvidjene_klase)
```



```
učitavanje podataka
podaci = pd.read_csv('podaci.csv')
rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
                                                           podaci za učenje (80%)
                                                                                       podaci za testiranje (20%)
    train_test_split(podaci['rijec'], podaci['klasa'],
    test size=0.2)
                                                                                             R
transformator = CountVectorizer(
                                                                         n-gram transformacija
      ngram_range=(1, 3), analyzer='char')
                                                                K
ngram_ucenje = transformator.fit_transform(
      rijeci_ucenje)
                                                                       n-grami za
                                                                                         n-grami za
                                                                         učenje
                                                                                         testiranje
ngram_test = transformator.transform(rijeci_test)
model = RandomForestClassifier(
      n_estimators=100, max_depth=3)
                                                                    model
rezultati = cross_val_score(
      model, ngram_ucenje, klase_ucenje)
                                                                 optimizacija
print(f'Avg F1 {rezultati.mean():.3f}') # Avg F1 0.870
                                                                učenje modela
                                                                                         predviđanje
model.fit(ngram_ucenje, klase_ucenje)
predvidjene_klase = model.predict(ngram_test)
                                                                                               validacija
rezultat = f1_score(klase_test, predvidjene_klase)
                                                                                                rezultati
print(f'F1 rezultat: {rezultat:.3f}') # F1 rezultat: 0.863
```

```
učitavanje podataka
podaci = pd.read_csv('podaci.csv')
rijeci_ucenje, rijeci_test, klase_ucenje, klase_test =\
                                                           podaci za učenje (80%)
                                                                                       podaci za testiranje (20%)
    train_test_split(podaci['rijec'], podaci['klasa'],
    test size=0.2)
                                                                                             R
transformator = CountVectorizer(
                                                                         n-gram transformacija
      ngram_range=(1, 3), analyzer='char')
                                                                K
ngram_ucenje = transformator.fit_transform(
      rijeci_ucenje)
                                                                       n-grami za
                                                                                         n-grami za
                                                                         učenje
                                                                                         testiranje
ngram_test = transformator.transform(rijeci_test)
model = RandomForestClassifier(
      n_estimators=100, max_depth=3)
                                                                    model
rezultati = cross_val_score(
      model, ngram_ucenje, klase_ucenje)
                                                                 optimizacija
print(f'Avg F1 {rezultati.mean():.3f}') # Avg F1 0.870
                                                                                         predviđanje
                                                                učenje modela
model.fit(ngram_ucenje, klase_ucenje)
predvidjene_klase = model.predict(ngram_test)
                                                                                               validacija
rezultat = f1_score(klase_test, predvidjene_klase)
                                                                                                rezultati
print(f'F1 rezultat: {rezultat:.3f}') # F1 rezultat: 0.863
```

github.com/laconlab/lacon-workshop-2021